

Blatt 6

16

a) Satz von Bayes: $P(F|W) = \frac{P(W|F) \cdot P(F)}{P(W)}$

Bedingte Wahrscheinlichkeit: $P(A|B) = \frac{P(A \cap B)}{P(B)}$

$P(A \cap B)$: Wahrscheinlichkeit, dass A und B gemeinsam auftreten.

$$P(F|W) = \frac{P(W \cap F)}{P(W)} = \frac{\frac{P(W \cap F)}{P(F)} \cdot P(F)}{P(W)} = \frac{P(W|F) \cdot P(F)}{P(W)}$$

Der Satz von Bayes folgt direkt aus der Definition der bedingten Wahrscheinlichkeit.

b)

Zunächst die Wahrscheinlichkeiten für die gegebenen Ereignisse einzeln:

$$P_{\text{starker Wind}} = 1/3$$

$$P_{\text{hohe Feuchtigkeit}} = 1/3$$

$$P_{\text{kalte Temperatur}} = 1/3$$

$$P_{\text{sonnig}} = 2/9$$

=>

$$P(W|F) = \frac{2}{243} \approx 8,23 \cdot 10^{-3}$$

Die gesamte Wahrscheinlichkeit, dass Fußball gespielt wird ist $\frac{36}{56} = \frac{9}{14}$.

Nun muss noch berechnet werden wie wahrscheinlich es ist, dass die Wetterbedingungen des heutigen Tages eintreffen. Das ist dann $P(W)$

$$P_{\text{starker Wind}} = 6/14$$

$$P_{\text{hohe Feuchtigkeit}} = 7/14$$

$$P_{\text{kalte Temperatur}} = 6/14$$

$$P_{\text{sonnig}} = 3/14$$

=>

$$P(W) = \frac{27}{1372} \approx 1,967 \cdot 10^{-2}$$

Damit muss die berechnete Wahrscheinlichkeit fürs Fußballspielen normiert werden.

$$P(F|W) = \frac{P(W|F) \cdot P(F)}{P(W)} = \frac{\frac{2}{243}}{\frac{27}{1372}} \cdot \frac{9}{14} = \frac{196}{729} \approx 0,2689$$

c)

$$P_{\text{Wind}} = 2/3$$

$$P_{\text{Regen}} = 1/3$$

$$P_{\text{Nebel}} = 0$$

$$P_{\text{Anblick}} = 2/9$$

=>

$$P(W|F) = 0$$

Damit wird auch $P(F|W) = 0$ sein. Das Problem liegt darin, dass in dem vorliegenden Datensatz noch nie bei heißem Wetter gespielt wurde und somit die Wahrscheinlichkeit dafür, bei heißem Wetter zu spielen 0 ist.

Man kann das Problem durch einen größeren Datensatz behoben werden, in dem dann auch etwas unwahrscheinlichere Ereignisse auftreten.

17

a)

$$H(Y) = \sum_{z \in Z} P(Y=z) \log_2 P(Y=z)$$

Die möglichen Ereignisse sind "Fußball spielen" und "nicht Fußball spielen".

Es ergibt sich also

$$\begin{aligned} H(\text{Fußball}) &= - \left(\frac{n_{\text{Fußball}}}{n} \log_2 \left(\frac{n_{\text{Fußball}}}{n} \right) + \frac{n_{\text{keinFußball}}}{n} \log_2 \left(\frac{n_{\text{keinFußball}}}{n} \right) \right) \\ &= - \left(\frac{9}{14} \log_2 \left(\frac{9}{14} \right) + \frac{5}{14} \log_2 \left(\frac{5}{14} \right) \right) \\ &\approx 0,94029 \end{aligned}$$

b)

Für die Berechnung des Informationsgewinns braucht man die Entropie nach einem Schnitt bzgl. des Attributs Wind. Allgemein ist die Entropie nach einem Schnitt

$$\begin{aligned} H(Y|X) &= \sum_{m \in M} P(X=m) H(Y|X=m) \\ &= - \sum_{m \in M} P(X=m) \sum_{z \in Z} P(Y=z|X=m) \log_2 P(Y=z|X=m) \end{aligned}$$

In diesem Fall wird das zu

$$H(\text{Fußball}|X) = \frac{n_{\text{Wind}}}{n} H(\text{Fußball}|\text{Wind}) + \frac{n_{\text{keinWind}}}{n} H(\text{Fußball}|\text{keinWind})$$

$$\begin{aligned} H(\text{Fußball}|\text{Wind}) &= - \left(\frac{n_{\text{Fußball, Wind}}}{n_{\text{Wind}}} \log_2 \left(\frac{n_{\text{Fußball, Wind}}}{n_{\text{Wind}}} \right) + \frac{n_{\text{keinFußball, Wind}}}{n_{\text{Wind}}} \log_2 \left(\frac{n_{\text{keinFußball, Wind}}}{n_{\text{Wind}}} \right) \right) \\ &= - \left(\frac{3}{6} \log_2 \left(\frac{3}{6} \right) + \frac{3}{6} \log_2 \left(\frac{3}{6} \right) \right) \\ &= 1 \end{aligned}$$

$$\begin{aligned}
 H(\text{Fußball} | \text{keinWind}) &= - \left(\frac{n_{\text{Fußball, keinWind}}}{n_{\text{keinWind}}} \log_2 \left(\frac{n_{\text{Fußball, keinWind}}}{n_{\text{keinWind}}} \right) + \frac{n_{\text{keinFußball, keinWind}}}{n_{\text{keinWind}}} \log_2 \left(\frac{n_{\text{keinFußball, keinWind}}}{n_{\text{keinWind}}} \right) \right) \\
 &= - \left(\frac{6}{8} \log_2 \left(\frac{6}{8} \right) + \frac{2}{8} \log_2 \left(\frac{2}{8} \right) \right) \\
 &\approx 0,811278
 \end{aligned}$$

$$\begin{aligned}
 \Rightarrow H(\text{Fußball}, X) &= \frac{6}{14} H(\text{Fußball} | \text{Wind}) + \frac{8}{14} H(\text{Fußball} | \text{keinWind}) \\
 &\approx 0,89216
 \end{aligned}$$

Der Informationsgewinn nach einem Schnitt auf dem Attribut Wind ist also:

$$IG(\text{Fußball} | \text{Wind}) = H(\text{Fußball}) - H(\text{Fußball} | X) \approx 0,09813$$

Rest: siehe Jupyter Notebook